

OpenNutri Yapay Zeka / Algoritma Ana Savunması

Arasınav sunumu | Erişim, sıralama, iki dilli arama ve
geri besleme kullanımı

Rol çerçevesi

Birden fazla bilimsel kaynak üzerinde
erişim tasarımı

PDF ediniminden önce sıralama mantığı

EN/TR dil ayrımı ve Türkçe kaynak desteği

Anotasyon çıktılarından geri besleme
kullanımı

Arasınav ana iddiası

**OpenNutri şimdiden arama,
filtreleme, PDF edinimi,
anotasyon ve geri besleme
kullanımını bağlayan kapalı
bir döngü olarak
çalışmaktadır.**

Bu sunum, bu döngüyü yapay zeka /
algoritma tarafından açıklar ve ardından
savunmada önemli olabilecek uygulama
ayrıntlarına iner.

Bu katman neden var

Algoritmik problem yalnızca makale toplamak değildir; hangi makalelerin indirilmeye ve uzman zamanına değdiğini seçmektir.

01

Dağınık literatür

Uygun gıda bileşimi makaleleri Europe PMC, OpenAlex, Semantic Scholar, DergiPark ve yerel açık erişim yollarına dağılmıştır. Tek kaynaklı strateji çok şey kaçıır.

02

Yüksek edinim maliyeti

Her aday PDF'yi körlemesine indirmek pahalı, gürültülü ve verimsizdir. Sistem yalnızca indirmeden sonra değil, edinimden önce de sıralama gerektirir.

03

Türkçe görünürlük açığı

Türkçe çalışmalar standart uluslararası gıda-veri sistemlerinde eksik temsil edilir. Bu nedenle erişim, açık EN/TR ayrımı ve Türkçe kaynak desteği gerektirir.

Yapay zeka katmanının amacı: geri çağırmaı korurken ve gereksiz PDF işini önlerken annotator'a giden yararlı makale akışını en üst düzeye çıkarmaktır.

OpenNutri arasınavda nedir

Yapay zeka rolü açısından önemli nokta, projenin ayrı bir scraper, backend ve arayüz değil, birbirine bağlı tek bir döngü olmasıdır.



Ne olduğudur

İnsan döngüsünde çalışan bilimsel makale keşif sistemi

Crawler, depolama ve anotasyon arasında ortak veri sözleşmesi

Sonraki çalıştırmaları değiştiren geri besleme güdümlü erişim sistemi

Ne olmadığıdır

Her şeyi indiren tek seferlik bir scraper değildir

Yalnızca bir veritabanı şeması veya yalnızca bir etiketleme arayüzü değildir

Henüz tamamen otomatik bir çıkarım motoru değildir

Uçtan uca mimari

Mimari, keşif, depolama, anotasyon ve sonraki geri besleme kullanımını şimdiden bağlıyor. Bu, sunumun geri kalanı için sistem haritasıdır.

Bu şekil nasıl okunur

Arama kaynakları meta veri adayları üretir.
Crawler hangi adayların edinime değdiğine karar verir.


Kabul edilen makaleler Supabase depolamasına ve paper kayıtlarına taşınır.

Annotator yapılandırılmış food-item ve nutrient kanıtı oluşturur.

Label event'ler ve global label'lar sonraki erişim döngüsünü besler.

**Ana savunma noktası: yapay zeka katmanı
üründen kopuk değil, gerçek kullanıcı
kararlarına bağlıdır.**

OpenNutri Arasınav Mimarisi



Kapalı döngü mantığı: uzman etiketleri yalnızca son çıktı değildir; daha sonraki tarama ve sıralama kararlarını da besler.

Yapay zeka açısından ilgili ortak veri modeli

Erişim katmanı paper kayıtlarına, arama kanıtına, kullanıcı event'lerine ve ortak bir sözlüğe dayanır.

Referans sözlük: entities, alias'lar ve master nutrient'ler hem erişim hem anotasyon tarafından yeniden kullanılır.

Paper alımı: papers tablosu, arayüz için mevcut kabul edilmiş PDF düzeyi kayıtları tutar.


Arama kanıtı: paper_search_hits, paper_search_batches ve paper_search_batch_hits, bir paper'ın sisteme neden girdiğini korur.

Geri besleme kanıtı: paper_label_events, paper_global_labels ve search_sessions, sonraki sıralama güncellemeleri için kullanıcı davranışını korur.

Önemli ayrım: ham arama kanıtı, kabul edilmiş paper kayıtlarından ayrı tutulur.

OpenNutri Veritabanı Yapısı (Sadeleştirilmiş)

UI ve crawler aynı Supabase seması üzerinden çalışır



Bu şekil tam bir ER diyagramı değil; migration.sql içindeki çekirdek tabloları, projeyi anlamayı kolaylaştıracak dört sorumluluk alanı altında toplar.

Arama katmanı ve dil ayrımı

Crawler tasarım gereği çok kaynaklıdır ve İngilizce ile Türkçeyi tek birleşik havuz yerine farklı erişim ortamları olarak ele alır.

Europe PMC

Ana açık erişimli biyomedikal yüzey; İngilizce için en güçlü varsayılan öncelik.

OpenAlex

Her iki dilde de kullanılan geniş meta veri kapsamı.

Semantic Scholar

Ek keşif yolu ve duplicate farkındalıklı kanıt.

DergiPark

Temel Türkçe kaynak; Türkçede en yüksek statik öncelik.

EN

Varsayılan öncelik Europe PMC'yi, sonra OpenAlex'i öne çıkarır.

İngilizce composition frame'ler ve phrase havuzları dil kapsamlı kalır.


TR

Varsayılan öncelik DergiPark'ı, sonra OpenAlex ve Semantic Scholar'ı öne çıkarır.

Ayrı anchor, phrase ve feedback score yapıları Türkçe davranışı dil kapsamlı tutar.

Sorgu oluřturma

Crawler sabit bir sorgu listesine dayanmaz. Temel composition sorgularını, öğrenilmiş query phrase'leri ve dönen bir concept havuzunu birleřtirir.



Dil-özgü temel composition şablonlarıyla başlar.
Food term'leri ve nutrient term'leri tek concept havuzunda iç içe geçirir.
Concept'leri önceki sonuçlardan öğrenilen concept_scores ile yeniden sıralar.
Çekirdek phrase'leri, daha uzun havuzdan küçük bir exploration bölümüyle karıştırır.

Tam uygulama tercihleri

Ek phrase'ler için exploration oranı: phrase havuzunun yüzde 2'si.
Her dil için ayrı cursor korunur.
Nutrient odaklı öğrenilmiş sorgular mg/100g veya g/100g gibi birim çerçevesi ekler.
Sorgular arama görevi genişletmesinden önce normalize edilip eşsizleştirilir.

Arama görevi önceliklendirmesi

Sorgu oluşturulduktan sonra her sorgu kaynağa özgü arama görevlerine genişletilir ve çalıştırmadan önce sıralanır.

Öncelik puanı

$$\text{priority_score} = \text{pair_score} + \text{batch_score}$$

$\text{pair_score} = \text{öğrenilmiş pair feedback} + 0.15 \times \text{source_prior} + \text{statik kaynak önceliği}$

batch_score , tam batch key'in tarihsel performansından gelir

Görevler azalan sırada sıralanır ve çalıştırma bütçesine göre kesilir

Dile göre statik kaynak önceliği

EN:

Europe PMC +0.35

OpenAlex +0.15

Semantic Scholar +0.05

DergiPark -0.15

TR:

DergiPark +0.35

OpenAlex +0.20

Semantic Scholar +0.10

Europe PMC -0.30

Sistem dil stratejisini bu şekilde çalıştırma sırasına dönüştürür.

Arama kapısı

Arama kapısı ucuz bir ilk meta veri taramasıdır. Daha ağır meta veri filtresi ve edinim aşamalarından önce zayıf adayları reddeder.

Pozitif sinyaller

İlk anchor/composition phrase eşleşmesi (+0.90)
İlk food term eşleşmesi (+0.35)
İlk nutrient term eşleşmesi (+0.35)
mg/100g veya g/100g gibi birim örüntüsü (+0.70)
Food + nutrient kombinasyon bonusu (+0.45)

Cezalar ve geçiş kuralı

Eksik meta veri -> -2.0 puanla doğrudan ret
Eksik özet cezası: -1.30 veya -0.45
Güçlü negatif sinyaller en fazla -2.5 ceza alır
Yumuşak negatifler en fazla -1.5 ceza alır
Sağlık sonucu terimleri en fazla -1.6 ceza alır
Geçiş eşiği: score $\geq$ -0.35

Meta veri filtresi

Meta veri filtresi daha güçlü toplamsal karar katmanıdır. PDF ediniminden önce sözcüksel işaretleri, kaynak önceliklerini, embedding'leri ve feedback term'lerini birleştirir.

Temel kanıt

Composition phrase +1.35

Birim örüntüsü +1.25

Food hit +0.65 ve nutrient hit +0.65

Food + nutrient kombinasyonu +0.75

Eksik özet cezası -1.10 veya -0.35

Sağlık sonucu cezası en fazla -2.0

Öğrenilmiş ve anlamsal kanıt

Tarihsel pozitif/negatif dengesinden gelen kaynak önceliği, +/-0.9 ile sınırlandırılır

Embedding benzerliği, benzerlik dil eşiğini aşarsa +1.45 ekler

Embedding benzerliği eşik üzerindeyse ek +0.75 eklenir

Feedback n-gram skoru toplanır ve +/-6.0 ile sınırlandırılır

Kabul eşiği: score ≥ 1.75

Embedding katmanı

Embedding'ler bağımsız bir sınıflandırıcı değil, meta veri puanlamasının içindeki anlamsal destek katmanıdır.

İngilizce model

all-MiniLM-L6-v2
threshold = 0.45

Türkçe / çok dilli model

paraphrase-multilingual-MiniLM-L12-v2
threshold = 0.42

Ortak kural

Encoding'den önce meta veri metnini
1800 karaktere kırp.

Skor nasıl üretilir

Anchor phrase'leri feedback config'den yükle; gerekirse
seed anchor'lara dön.

Aday başlık + özeti dil-özgü modelde encode et.

Tüm anchor'lara karşı normalize benzerliği hesapla ve
en yüksek eşleşmeyi tut.

Bu tasarım neden seçildi

Anchor'lar anlamsal hedefi dar tutar: genel
beslenmeden çok composition odaklı.

İki model EN ve TR puanlamasını dil duyarlı tutar.

Bu katman, tam anahtar kelimelerin kaçırabileceği
anlamsal olarak ilgili ifadeleri yakalar.

Geri besleme etiketleri ve eğitim kümeleri

Öğrenme döngüsü ham event toplamlarına değil, her annotator'ün görünen son durumuna dayanır.

Pozitif paper: has_data = true, food-item sayısı > 0 ve nutrient-value sayısı > 0 olan son draft veya done durumu.


Negatif paper: global definitely-no-data etiketi veya en az iki farklı skip kullanıcısı.

Çelişkili paper: hem pozitif hem negatif kanıt içerir; öğrenmeden çıkarılır.

İşleme, etiket kurulumu sonrası dil-özgü yürütülür.

Önemli nokta: geri besleme döngüsü uygulanmıştır, ancak çevrim içi değil toplu güncellenir.

Anotasyon ve Feedback Veri İlişkisi



Geri besleme sonraki çalıştırmalarda neyi değiştirir

Döngü hâlihazırda aktiftir. Geri besleme yalnızca saklanmaz; yeni bir config'e aktarılır ve bir sonraki crawler çalıştırması tarafından kullanılır.



query_phrases
anchor_phrases
weighted_terms
concept_scores
pair_scores, batch_scores, source_priors

Sonraki çalıştırmalar farklı phrase'leri farklı sıralarda arar.

Concept sıralaması hangi food veya nutrient'lerin önce birleşeceğini değiştirir.

Daha iyi verim veren source-query kombinasyonları kuyruğun üstüne çıkar.

Operasyonel kapanış

Refill betiği, annotator kuyruğu azaldığında algoritmik parçaları çalışan operasyonel bir döngüye dönüştüren bileşendir.



Sistem paper stoğu hedefin altına düştüğünde tepki verebilir.

Feedback yenilemesi varsayılan olarak refill döngüsünün parçasıdır.

DergiPark yenilemesi Türkçe havuzu yenilenebilir tutar.

Buradaki en güçlü cümle şudur:
“Mevcut sistem yalnızca deneysel değil, operasyoneldir: geri beslemeyi yenileyebilir, yeni makaleler arayabilir ve kabul edilen PDF'leri tekrar annotator hattına itebilir.”

Yapay zeka açısından ilgili arayüz etkileşimi

Frontend yalnızca veri girişi değildir. Erişim katmanının daha sonra öğrenebileceği yapılandırılmış kanıtı da yakalar.

PDF highlight ve tıklama çözümleme

Nutrient adları sınır duyarlı regex kalıplarıyla eşleştirilir, mark etiketlerine sarılır ve PDF.js text layer düzensiz davrandığında direct-target, elementsFromPoint veya caret tabanlı fallback ile açılır.

Hızlı ekleme popover'ı ve yapılandırılmış kayıt

Tıklanan nutrient, highlight yanında bir popover açar; değer ve birim alır ve mevcut food-item formuna yapılandırılmış nutrient satırı ekler.

Autocomplete sıralaması ve telemetri

Food ve nutrient aramaları özel sıralama kuralları kullanır; search_sessions ise yazılan sorguları, gösterilen seçenekleri, seçilen seçenekleri ve terk edilen durumları kaydeder.

Mevcut durum ve kapsam sınırı

Bu slayt aşırı iddiaya kaçmadan teknik olarak güçlü kalmak içindir.

Şu anda uygulananlar

Europe PMC, OpenAlex, Semantic Scholar ve DergiPark üzerinde çok kaynaklı arama

Edinimden önce arama kapısı ve daha güçlü meta veri filtresi

Meta veri puanlaması içinde çift model embedding desteği

Sonraki çalıştırmaları değiştiren toplu güncellenmiş geri besleme döngüsü

Paper stoğuna bağlı operasyonel refill döngüsü

Arasınavda iddia edilmeyenler

Henüz query ranking için eğitilmiş sınıflandırıcı yok

LLM tabanlı search-term ranking yok

Mevcut döngüde tam otomatik extraction pipeline yok

Document segmentation ve extraction ikinci döneme ertelenmiştir

Savunma özeti

Tüm yapay zeka hikâyesini birkaç iddiaya sıkıştırmak gerekseydi, güçlü biçimde savunulması gerekenler bunlardır.

İddia 1

Sistem edinimden önce aşamalı filtreleme yapar. Uzman zamanının her getirilen paper üzerinde boşa gitmemesinin temel nedeni budur.

İddia 2

İngilizce ve Türkçe ayrı erişim havuzlarıdır. Bu yalnızca sunum detayı değil, gerçek bir teknik karardır ve DergiPark bu stratejinin parçasıdır.

İddia 3

Geri besleme döngüsü şu anda uygulanmıştır. Sonraki çalışmalar için phrase'leri, weighted term'leri ve source/query önceliklerini günceller.

Zorlanırsanız bu üç iddiaya geri dönün ve sonra tek bir somut uygulama detayıyla cevap verin.

Ek: uygulama ayrıntıları ve soru-cevap

Sonraki slaytlar uzun kurul soruları için tasarlanmıştır.

Ek: uygulama ayrıntıları ve soru-cevap

Ek bölüm; şema kesitlerine, tam eşiklere, feedback kurallarına, arayüz iç yapısına ve kuruldaki gelebilecek yaygın sorular için güvenli cevaplara daha derin iner.

Ek A. Kaynaklar ve dil stratejisi

Bu, birden fazla kaynak kullanmanın ve EN ile TR'yi tek sıralama havuzunda birleştirmemenin ayrıntılı gerekçesidir.

Europe PMC açık erişimli biyomedikal kapsama sağlar ve İngilizce için en güçlü varsayılan yüzeydir.

OpenAlex meta veri kapsamını genişletir ve PMC kapsamı zayıfken her iki dili destekler.

Semantic Scholar başka bir keşif yolu ve duplicate farkındalıklı kanıt ekler.

DergiPark temel Türkçe kaynaktır ve dile özgü Türkçe iş akışını gerektelendirir.

Farklı kaynak görünürlüğü

Farklı term yüzeyleri ve composition phrasing

Farklı source prior'lar ve statik öncelikler

Farklı anchor ve query-phrase havuzları

Ek B. Tam ağırlıklar ve eşikler

Bunlar iki ana sıralama aşaması için uygulanmış sabitlerdir.

Arama kapısı

composition phrase	+0.90
food term	+0.35
nutrient term	+0.35
unit pattern	+0.70
food + nutrient combo	+0.45
missing metadata	-2.00 ret
missing abstract	-1.30 veya -0.45
strong negatives	en fazla -2.50
soft negatives	en fazla -1.50
health terms	en fazla -1.60
geçiş için score	≥ -0.35

Meta veri filtresi

composition phrase	+1.35
unit pattern	+1.25
food hit	+0.65
nutrient hit	+0.65
food + nutrient combo	+0.75
embedding above threshold	+1.45
embedding positive bonus	+0.75
source prior clamp	± 0.90
feedback term clamp	± 2.50
feedback score clamp	± 6.00
kabul için score	≥ 1.75

Ek C. Feedback puanlama ayrıntısı

Bu slayt, feedback updater tarafından kullanılan tam etiket kurallarını ve term ranking mantığını birleştirir.

Pozitif = has_data = true ve gerçek yapılandırılmış satırlara sahip son draft/done

Negatif = global definitely-no-data veya en az iki farklı skip

Çatışma = hem pozitif hem negatif kanıt, öğrenmeden çıkarılır

```
query_rank = 1.75*title_good + 0.75*title_net +  
0.35*ta_net - max(0, title_bad)  
anchor_rank = 1.25*title_good + 1.0*ta_good +  
0.5*title_net + 0.25*ta_net - max(0, title_bad)
```

n-gram'ler başlıklardan ve başlık+özetten ayrı ayrı çıkarılır

pozitif, negatif ve arka plan belge frekansları log-odds benzeri puanlamayla karşılaştırılır

query_phrases varsayılan üst sınır = 64,
anchor_phrases varsayılan üst sınır = 16

weighted_terms tam scored-term yükünü sonraki meta veri puanlamasına taşır

Ek D. Pair, batch ve concept feedback

Feedback exporter phrase'lerden fazlasını öğrenir: hangi source-query kombinasyonlarının ve concept term'lerinin daha iyi sonuç ürettiğini de öğrenir.

Pair feedback

Search hit'leri source + template_id + source_term ile grupta.
 $\text{Score} = \text{novel_positive_count} / \text{retrieved}.$
Ayrıca $\text{source_priors} = \log((\text{positive} + 1) / (\text{negative} + 1))$ olarak türetilir.

Batch feedback


paper_search_batches ve paper_search_batch_hits üzerinde batch_key ile grupta.
 $\text{Score} = \text{positive_count} / \text{retrieved}.$

Concept feedback

source_term ile grupta.
 $\text{Score} = (\text{positive_count} - \text{negative_count}) / \text{retrieved}.$
Bu daha sonra concept havuzunu yeniden sıralar.

Ek E. Edinim ve doğrulama

Meta veri kabulünden sonra bile, paper'ların kabul edilmiş kayda dönüşmeden önce sağlam bir PDF yoluna ve tam metin doğrulama adımına ihtiyacı vardır.



Önce OA XML ve doğrudan PDF bağlantılarını dene.

Doğrudan bağlantı başarısız olursa paket çıkarımı veya HTML'den keşfedilen bağlantıları kullan.

Kararsız kaynak davranışı için curl / fallback yollarını kullan.

Tam metni pdftotext ile çıkar.

Composition çerçevesini, tablo/metot kanıtını, nutrient-birim sinyallerini ve food işaretlerini kontrol et.

Tam metin yararlılık kontrollerini yine de geçemeyen adayları reddet.

Ek F. Yapay zeka açısından ilgili arayüz iç yapısı

Kurul insan etkileşiminin nasıl yapılandırılmış sinyallere dönüştüğünü sorduğunda bu ayrıntılar önemlidir.

PDF highlight

Sınır duyarlı nutrient regex kalıpları oluştur, render sonrası PDF.js text span'lerini tara, eşleşmeleri mark etiketlerine sar ve kısa nutrient adlarının uzun olanları bozmaması için çakışmaları çöz.

Tıklama çözümleme

Önce doğrudan event target'ı dene, sonra elementsFromPoint'e, sonra caretPositionFromPoint veya caretRangeFromPoint'a dön; çünkü PDF.js text layer'ları normal HTML gibi davranmaz.

Autocomplete ve telemetri

Food ve nutrient autocomplete özel sıralama kuralları kullanır; search_sessions ise yazılan sorguları, gösterilen seçenekleri, seçilen seçenekleri, durumu ve zaman damgalarını kaydeder.

Ek G. Denetlenmiş örnek çalıştırma özeti


Bu slayt, örnek çalıştırmanın katı bir huni gibi yanlış okunmaması için aşama sayılarını kayıtlı edinim çıktılarından bilinçli olarak ayırır.

Aşama sayıları (TR canlı çalıştırma 2026-03-30)



Bu sayılar manifest özetinden gelir ve metadata_pass aşamasına kadar aşama sayıları olarak geçerlidir.

Kayıtlı edinim çıktıları



Önemli denetim notu: Bu manifestte 78 metadata-pass aday vardır, ancak bunların yalnızca 66'sının kayıtlı terminal sonucu vardır. Bu nedenle bu örnek katı bir huni olarak sunulmamalıdır.

Ek H. Olası sorular ve güvenli cevaplar

Baskı altında geri dönülmesi gereken kısa cevaplar bunlardır.

S: Geri besleme döngüsü uygulanmış mı?
C: Evet. Toplu güncelleniyor, çevrim içi değil ve sonraki crawler çalıştırmalarını şimdiden değiştiriyor.

S: Search term'leri sıralamak için LLM kullanıyor musunuz?
C: Hayır. Search-term ranking, LLM değil, feedback güdümlü istatistiksel puanlamadır.

S: Query ranking için model eğittiniz mi?
C: Henüz değil. Mevcut sistem, eğitilmiş sınıflandırıcıdan çok feedback istatistikleri ve embedding'lerle öğreniyor.

S: Neden her şeyi indirmiyorsunuz?
C: Çünkü meta veri filtreleme çok daha ucuzdur ve uzman zamanını korur.

S: Neden İngilizce ve Türkçeyi ayırıyorsunuz?
C: Çünkü kaynak kapsamı, terminoloji ve kaynak öncelikleri farklıdır.

S: Neden yalnızca embedding değil?
C: Birimler, composition phrase'ler ve food/nutrient kombinasyonları gibi alan ipuçları görmezden gelinemeyecek kadar değerlidir.